

Una mirada analítica a la competición hípica

TRABAJO DE FIN DE BOOTCAMP DE DATA ANALYTICS

ThePower - HackIO

Autor: Gabriela Jiménez Conde

Curso 2024-2025

Índice

1	Resumen ejecutivo	2
1.1	Descripción del caso de negocio	2
1.2	Objetivos e impacto esperado	2
1.3	Tecnologías y herramientas	2
1.4	Fuentes de datos	3
2	Proceso de ETL	3
2.1	Proceso de extracción	3
2.2	Proceso de transformación	3
2.3	Proceso de carga	4
2.4	Dificultades encontradas	4
3	Análisis exploratorio de datos	4
3.1	Análisis general	4
3.2	Análisis de pruebas y categorías	5
3.3	Análisis de binomios	6
3.4	Análisis de la base de datos	6
4	Desarrollo del dashboard	7
5	Conclusiones y próximos pasos	7
5.1	Conclusiones	7
5.2	Next steps	8

1. Resumen ejecutivo

1.1. Descripción del caso de negocio

Los números cuentan las historias detrás del deporte. En las competiciones, el análisis de datos permite entender el desempeño de los atletas, anticipar resultados y mejorar la toma de decisiones. Sin embargo, en la hípica nos encontramos con un problema: no existe la medición precisa y significativa del rendimiento de los binomios (jinete y caballo) en las pruebas.

La hípica no es un deporte lineal, sino que en cada competición influyen múltiples factores, desde el nivel de los binomios, la dificultad del recorrido, las condiciones del terreno, el estado físico del caballo y del jinete, entre otras cosas. Todo ello convierte a la competición ecuestre en un deporte singular, en el que incluso los mejores binomios tienen todas las probabilidades en su contra, además de convertirlo en un deporte difícil de comprender para quienes no están familiarizados con ella.

A ello, debemos incluir la escasa utilización y accesibilidad a los datos, lo que dificulta la toma de decisiones informadas tanto para los usuarios dentro del deporte, como jinetes, entrenadores u organizadores de eventos, como para los usuarios fuera del mismo, los fans. Este proyecto nace con el objetivo de modificar esta realidad, haciendo uso de los datos como herramienta estratégica e informativa, y para fomentar una mejor comprensión del deporte.

1.2. Objetivos e impacto esperado

El objetivo principal del proyecto es desvelar la historia detrás de los resultados de las competiciones. A través del análisis de datos, se busca aportar valor a la competición hípica, mejorando la comprensión, la toma de decisiones y la comunicación en el entorno del deporte ecuestre.

Es un proyecto enfocado a diferentes públicos. Para los fans, se busca mejorar la comprensión del deporte desde fuera. Para los jinetes, se realizará un análisis histórico de su rendimiento, enfocado en proporcionar feedback personalizado que permita optimizar los entrenamientos y realizar un establecimiento de objetivos en base a resultados pasados. Los organizadores de eventos y marcas tendrán a su disposición una forma de contar el deporte que permita mejorar el storytelling, llevando a mejorar el engagement de la audiencia. Los análisis estarán centrados en las tres disciplinas olímpicas: salto, doma y completo.

Para ello se va a desarrollar un dashboard interactivo en el que se representarán insights generales de la competición ecuestre, y se ofrecerán explicaciones sobre los resultados pasados. Por otro lado, se generará un sistema de predicción de resultados, que permita anticipar el rendimiento de los binomios en futuras competiciones.

1.3. Tecnologías y herramientas

El proyecto está dividido en varias fases, para las cuales se utilizarán diferentes herramientas:

- **Proceso de ETL:** se utilizarán herramientas de extracción de información, como streamlit, así como SQL con Python para la carga de los datos a la base, a través de herramientas como Psycpg2.

- **Proceso de EDA:** se utilizará SQL y herramientas de Python, como Pandas, matplotlib, seaborn o plotly express, con el fin de obtener insights relevantes.
- **Sistema predictivo:** se utilizarán herramientas de predicción a través de Python.
- **Dashboard e informe final:** se utilizará streamlit para la creación de insights de forma visual y entendible.

1.4. Fuentes de datos

Las fuentes de datos utilizadas en el proyecto se indican a continuación:

- **Página web de la RFHE** (<https://rfhe.com/>): es la fuente principal del proyecto, de la cual se obtendrá información sobre las competiciones, los jinetes y los caballos de forma detallada.
- **Página web de la FEI** (<https://www.fei.org/>): de esta fuente se obtiene información sobre regulación y sobre el funcionamiento general y el reglamento de las pruebas y disciplinas analizadas.
- **Equiratings** (<https://www.equiratings.com/>): de esta fuente se obtiene información sobre el modelo predictivo y sobre el funcionamiento del análisis de datos aplicado a la competición hípica.

2. Proceso de ETL

La recopilación y preparación de datos sobre la competición hípica ha seguido las etapas de un proceso de ETL (Extract, Transform, Load), con el objetivo de obtener un conjunto de datos disponible para ser analizado detalladamente. Este proceso es fundamental para asegurar que el resultado final del proceso sea un conjunto de datos limpio y estructurado. A continuación se detallan las etapas clave que ha seguido este procedimiento.

2.1. Proceso de extracción

La extracción de la información se ha realizado mediante un procedimiento de web scraping de la web de la Real Federación Hípica Española (RFHE, <https://rfhe.com/competiciones/>), haciendo uso de selenium, herramienta especializada en el testeo de páginas web y web scraping, a partir de los diferentes enlaces de las diferentes disciplinas a analizar: salto de obstáculos, concurso completo y doma clásica. En las mismas se puede encontrar un histórico de los concursos desde 2010 a nivel nacional e internacional.

El pipeline parte de los concursos anuales de la disciplina seleccionada, y va accediendo a cada uno, para obtener la información general de cada concurso, así como las pruebas llevadas a cabo en los mismos. Se han tenido solo en cuenta aquellos concursos que tienen resultados, sin obtener aquellos que han sido suspendidos o aplazados. Una vez se obtiene la información general así como las pruebas llevadas a cabo, a partir de la url de la primera prueba del concurso, se lanza un proceso que va obteniendo los archivos de tipo excel (xls) de cada prueba, los cuales contienen la información sobre los resultados de las pruebas.

2.2. Proceso de transformación

La transformación de los datos se inicia en el proceso de extracción. La información sobre los concursos es almacenada, según se ejecuta el proceso de extracción, en un archivo de

tipo json. La información sobre las pruebas y los resultados se obtiene mediante los excels descargados. Para obtener los resultados de las pruebas, se ha procedido a limpiar los archivos excel descargados, mediante el uso de pandas, herramienta de python especializada para el tratamiento de datos.

Dentro de cada excel se puede encontrar el nombre del concurso, el tipo de prueba, la fecha de la prueba, los resultados de los binomios, si han obtenido premio, y la puntuación realizada en la prueba realizada. Dependiendo del tipo de prueba, los resultados obtenidos tienen una estructura diferente, por lo que se han seccionado las puntuaciones y tiempos de los recorridos en diferentes columnas con el fin de utilizar esos resultados en el análisis. Una vez que el dataset de cada concurso y prueba está limpio, se procede a unir todos los diferentes datasets en uno mismo, obteniendo así todo el conjunto de datos en un mismo dataset limpio, preparado para ser cargado.

2.3. Proceso de carga

El proceso de carga se realiza a partir del conjunto de datos completo. El almacenamiento del dataset se hace a través de una base de datos relacional de PostgreSQL, con la estructura del siguiente ERD del siguiente enlace: [aquí](#). La información ha sido subida en el mismo orden de creación de las tablas de la base de datos. Para la carga se ha utilizado psycopg2, herramienta que permite conectar python con bases de datos de PostgreSQL.

2.4. Dificultades encontradas

La dificultad principal se encuentra en el proceso de web scraping, el cual es un proceso lento, ya que requiere de numerosas horas de extracción de información de la web de la RFHE. La extracción es de aproximadamente 300 concursos en cada año, lo cual ralentiza todo el proceso. Asimismo, la web no está completamente actualizada, ya que en cada click que se realiza, se abren nuevas pestañas.

Por otro lado, nos encontramos con la diferencia en los resultados según el tipo de prueba que se lleve a cabo, generando una serie de combinaciones a tener en cuenta a la hora de hacer la limpieza. A la hora de la carga, nos encontramos que hay concursos con el mismo nombre, generando dificultades a la hora de asignar ids adecuados a cada concurso, así como su unión con las pruebas y resultados adecuados.

3. Análisis exploratorio de datos

En esta sección realizamos un análisis de la competición española de salto de obstáculos en lo transcurrido en el año 2025. Para realizar el análisis se ha hecho uso de herramientas como PostgreSQL, para obtener información de manera directa desde la base de datos a través de queries, pandas para el tratamiento de datos, y plotly express para la creación de gráficos.


3.1. Análisis general

Se han celebrado un total de 122 concursos, entre el 2025-01-10 y el 2025-04-27, siendo una gran parte de ámbito internacional. El mes que más concursos se han realizado ha sido febrero, con un total de 41 concursos, y el mes que menos concursos se han realizado ha sido el mes de abril, con un total de 21 concursos. Tenemos que tener en cuenta que en

el mes de febrero se inician los conocidos como tours, como el Sunshine Tour o el Spring MET Tour, los cuales tienen una duración superior al mes.




Porcentaje de concursos por ámbito



Cabe destacar que un 61,48 % de los concursos se han realizado en la provincia de Valencia. Esto se debe a que en las localidades encontradas en esta provincia se dan las competiciones del Spring MET en el Centro Ecuestre Oliva Nova, y el Spring Tour en el centro de Moura Tours. Asimismo, se han realizado numerosos concursos en la provincia de Cádiz, entre ellos el Andalucía Sunshine Tour, en la localidad de Montenmedio.

Concursos por provincia



3.2. Análisis de pruebas y categorías

De media, en un concurso se realizan 13 pruebas. Nos encontramos con 14 tipos de pruebas diferentes, siendo las más comunes las siguientes:

- Baremo A con cronómetro (238.2.1)
- Baremo A con cronómetro y desempate (238.2.2)

- Dos fases, ambas con cronómetro (274.1.5.3)
- Dos fases especial (274.2)

Podemos ver que se han realizado concursos de competiciones de entre una y cinco estrellas, además de concursos de caballos jóvenes (YH), y de las categorías de children y jóvenes jinetes (Ch/J/Y). A continuación se puede observar de media el número de jinetes y caballos que asisten a un concurso de cada categoría, y el dinero que se reparte en premios de media en un concurso de cada categoría. Se observa claramente que aquellos concursos que son de ámbito internacional tienden a tener un mayor reparto de dinero en premios, así como atracción de jinetes y, por lo tanto, de caballos.

Categoría	Nº Jinetes medio	Nº Caballos medio	Dinero Medio Repartido
CSI****	335,25	809,76	393,141,89
CSI***	113,11	270,81	262,111,37
CSI**	121,86	286,88	91,725,00
CSI*	143,44	244,70	83,613,54
CSI YH*	154,20	348,28	53,165,94
CSN*****	175,92	286,92	37,879,63
CSN****	129,00	237,00	26,215,00
CSIO Ch/J/Y	77,00	108,00	22,900,00
CSN***	77,33	134,87	13,119,28
CSN**	124,69	179,20	6156,57
CSNCJ	35,56	44,72	2011,43
CSN*	31,84	37,01	1074,78

Cuadro 1: Estadísticas por categoría de concurso

3.3. Análisis de binomios

Consideramos un binomio como la combinación jinete-caballo. En los concursos analizados, hemos observado que han participado un total de 9.012 binomios, y se ha analizado que, de media, un jinete sale a pista con tres caballos diferentes. Del total de caballos que tenemos, que son 8.333, un 21,44 % se consideran caballos jóvenes, ya que han participado en pruebas de 5, 6 y 7 años.

Edad caballo	Nº caballos
5 años	347
6 años	701
7 años	738

Cuadro 2: Número de caballos por edad

3.4. Análisis de la base de datos

A través de haber realizado un análisis de los datos que contiene la base, hemos observado que existen errores a nivel técnico. Hay concursos con el mismo nombre, que contienen ids diferentes. Este error proviene de la recopilación de los datos. En la fuente de información de la que se obtiene la información, la RFHE, los concursos se registran de manera semanal, de manera que un concurso que dure más de una semana se verá dividido en dos. También nos encontramos con el caso de concursos que se celebren en meses diferentes, pero es el

mismo concurso (a nivel de nombre). La asignación de ids a la hora de realizar la carga a la base se realizó teniendo en cuenta la unicidad del concurso en función de la fecha. A continuación, vemos una serie de ejemplos de esta casuística:

id_concurso	concurso	localidad	fecha_inicio	fecha_fin
87	SPRING MET III 2025 - CSI3* GOLD	Centro Ecuestre Oliva Nova	2025-03-20	2025-03-23
96	SPRING MET III 2025 - CSI3* GOLD	Centro Ecuestre Oliva Nova	2025-03-27	2025-03-30
20	CSN2* LAS CADENAS	Club Hipico Las Cadenas	2025-01-25	2025-01-26
46	CSN2* LAS CADENAS	Las Cadenas	2025-02-15	2025-02-16
100	CSN2* LAS CADENAS	Club Hipico Las Cadenas	2025-03-29	2025-03-30

Se recomienda realizar una modificación de la base de datos, que tenga en cuenta estas casuísticas, para poder realizar una asignación de los ids de concurso de manera consistente.

Por otro lado, nos encontramos que a un mismo centro se le denomina con diferentes nombres en la base en la columna de localidad, como en los siguientes casos:

- Valencia: Centro Ecuestre Oliva Nova, Moura Tours, Ceon, Mouratours Valencia, Mouratours.
- Madrid: Club Hipico Las Cadenas, R.A.C.E., Las Cadenas, R.S.H.E.C.C..

Podemos observar de las dos provincias seleccionadas las localidades en las que se han realizado concursos en las mismas. En Valencia observamos que existen diferentes nombres para el Moura Tours, y el Centro de Oliva Nova, y en Madrid para el club de Las Cadenas. Se recomienda analizar detenidamente estas casuísticas, y asignar un nombre único a cada localidad/centro, para evitar inconsistencias en la base.

4. Desarrollo del dashboard

Una vez se ha realizado un análisis detallado del dataset de los concursos, es necesario tener una herramienta a la que se puede acceder a la consulta de estos resultados y análisis. Por ello se ha desarrollado una web que permite obtener acceso al análisis general de la competición española de salto de obstáculos, a los resultados de los diferentes concursos, y al análisis del rendimiento de los binomios. Para ello se ha hecho uso de streamlit, un framework que permite crear aplicaciones web de forma sencilla y rápida. La estructura del mismo se divide en una página principal que contiene un análisis detallado de las competiciones, una página que permite obtener acceso a los resultados de los concursos, y una página que permite acceder al análisis de los binomios.

5. Conclusiones y próximos pasos

5.1. Conclusiones

En este proyecto vemos una representación de técnicas de análisis de datos en la competición hípica en España. Se ha generado un proceso de recolección de información que facilita la actualización continua de datos, suponiendo esto una base sólida para futuros análisis.

A través de la herramienta creada haciendo uso de streamlit, se puede realizar un análisis del rendimiento de los binomios, hacer un análisis general de las competiciones hípicas en España, además de ser una forma de acceso sencilla y al alcance de todos de información sobre los concursos de salto de obstáculos en España.

5.2. Next steps

Inicialmente, se buscaba analizar las disciplinas olímpicas del deporte ecuestre. En este proyecto se realiza un análisis de las disciplinas de salto de obstáculos en España durante el año 2025. A partir de este punto se plantean a continuación una serie de líneas de trabajo para desarrollar a futuro:

- Generar un análisis histórico y detallado de la competición de las disciplinas olímpicas, tanto a nivel nacional, como a nivel internacional.
- Información sobre ingresos/costes a través de los avances de programa de cada competición hípica, así como de los Fei Annual Reports, de manera que se pueda realizar un análisis de ingresos/costes de las competiciones.
- Crear un sistema predictivo que permita hacer pronósticos sobre los resultados en futuras competiciones.
- Realizar la corrección de errores menores en la base de datos.